

第一章 非线性凸规划

Definition 1.0.1. 非线性规划的数学模型

$$\begin{aligned} \min & f(X) \\ \text{s.t.} & h_i(X) = 0 \quad i = 1, 2, \dots, m \\ & g_j(X) \geq 0 \quad j = 1, 2, \dots, l \\ & X \in R^n \end{aligned}$$

何老师的问题:非线性规划找的是局部最小点还是全局最小点?

实际上对于非线性凸规划,我们找到的局部最小点就是全局最小点。对于复杂的非线性规划,实际上我们不确定找到的是局部最小点还是全局最小点。

Definition 1.0.2. 凸函数与凹函数

凸函数为满足下列条件的函数:

$$f[\lambda X_1 + (1 - \lambda)X_2] \leq \lambda f(X_1) + (1 - \lambda)f(X_2) \quad 0 < \lambda < 1 \quad X_1, X_2 \in R^n$$

Proof. 证明凸函数的局部最小点就是全局最小点

对于任意 $\theta \in [0, 1]$, 验证:

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

展开左边并整理后, 比较两边的差值为:

$$\frac{\theta(1 - \theta)}{2}(x - y)^T A(x - y) \leq 0$$

由于 A 半正定且 $\theta(1 - \theta) \geq 0$, 不等式成立, 故 f 是凸函数。 □

凸函数的性质

1. 凸函数非负线性组合仍为凸函数

$$\gamma_1 f_1(X) + \gamma_2 f_2(X) \quad \gamma_i \geq 0$$

2. 若 $f(X)$ 是定义在凸集 R_C 上的凸函数, 则其 β 水平集 S_β 为凸集。

$$S_\beta = \{X \mid f(X) \leq \beta, X \in R_C\} \quad \beta \text{水平集}$$

3. 对于凸函数 $f(X)$, 若存在 $X^* \in R^n$ 满足

$$\nabla f(X^*)^T (X - X^*) \geq 0 \quad \forall X \in R^n$$

则 X^* 为 $f(X)$ 的全局最小点。充要条件!

(1)(3)显然,(3)先证明是局部最小点, 然后证明的全局最小点。

对于(2), 直接使用定义是可以证明的。

Definition 1.0.3. 凸规划问题

$$\min f(X)$$

s.t. $h_i(X) = 0 \quad i = 1, 2, \dots, m$ 线性函数

$$g_j(X) \geq 0 \quad j = 1, 2, \dots, l \quad \text{凹函数}$$

$$X \in R^n$$

实际上第二个凹函数的要求, 如果是左右同乘一个负号, 实际上是一个凸函数。所以这个规划问题的可行域也是个凸集(线性函数是凸函数也是凹函数)。

Theorem 1.0.1. 若目标函数为严格凸函数, 则如果全局最优解存在必为唯一全局最优解。(反证法)

如果不是严格, 我们用定义可以说明凸函数的最优解解集一定是各个最优解的凸包

Definition 1.0.4. 海森矩阵

$$\nabla^2 f(X) = \begin{bmatrix} \frac{\partial^2 f(X)}{\partial x_1^2} & \frac{\partial^2 f(X)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(X)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(X)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(X)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(X)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(X)}{\partial x_n \partial x_1} & \frac{\partial^2 f(X)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(X)}{\partial x_n^2} \end{bmatrix}$$

$$f(X + \Delta X) = f(X) + \nabla f(X)^T \Delta X + \frac{1}{2} \Delta X^T \nabla^2 f(X) \Delta X + O(\|\Delta X\|^2)$$

如果某处梯度为0，海森矩阵为半正定，实际上这只是局部极小值的必要条件。除非加强为领域梯度均大于等于0。

Definition 1.0.5. 拉格朗日乘数法(针对等式约束):

定义Lagrange函数

$$\min L(X, \lambda) = f(X) + \lambda^T h(X) = f(X) + \sum_{i=1}^m \lambda_i h_i(X)$$

$$\lambda = [\lambda_1 \quad \lambda_2 \quad \cdots \quad \lambda_m]^T$$

求无约束极值问题:

$$\left. \frac{\partial L(X, \lambda)}{\partial X} \right|_{X^*} = 0 \Rightarrow \nabla f(X^*) + \sum_{i=1}^m \lambda_i \nabla h_i(X^*) = 0$$

$$\left. \frac{\partial L(X, \lambda)}{\partial \lambda} \right|_{\lambda^*} = 0 \Rightarrow h_i(X^*) = 0 \quad i = 1, 2, \dots, m$$

不等式约束极值问题:

$$\min f(X)$$

$$\text{s.t. } g_j(X) \geq 0 \quad j = 1, 2, \dots, l$$

$$X \in R^n$$

Definition 1.0.6. 定义: 令目标函数值 $f(X^{(0)})$ 下降的方向, 满足

$$\exists \lambda_0 > 0, \text{ 对于 } \forall \lambda \in (0, \lambda_0], \text{ 有 } f(X^{(0)} + \lambda P) < f(X^{(0)})$$

判别条件: $\nabla f(X^{(0)})^T P < 0$

Theorem 1.0.2. Gordan 引理

A_j 为一组已知向量, 不存在向量 P , 使

$$A_j^T P < 0 \quad j = 1, 2, \dots, l$$

同时成立的充要条件:

存在不全为零的非负实数 $\mu_j \geq 0$, 使

$$\sum_{j=1}^l \mu_j A_j = 0$$

几何含义: A_j 不可能分布在任何超平面的同一侧。

Proof. 用Farkas引理证明Gordan引理

Farkas引理: 对于矩阵 $A \in \mathbb{R}^{m \times n}$ 和向量 $b \in \mathbb{R}^m$, 以下两个系统恰有一个有解:

1. 存在 $x \geq 0$ 使得 $Ax = b$;
2. 存在 $y \in \mathbb{R}^m$ 使得 $y^\top A \geq 0^\top$ 且 $y^\top b < 0$ 。

证明Gordan引理:

1. 构造辅助系统:

将系统A加强为存在满足归一化条件的解。令 $e = (1, 1, \dots, 1)^\top$, 定义新系统:

$$\exists x \geq 0, \quad \begin{cases} Ax = 0 \\ e^\top x = 1 \end{cases}$$

若此系统有解, 则原系统A有非零解; 反之则无。

2. 应用Farkas引理:

将上述系统写作矩阵形式 $\begin{bmatrix} A \\ e^\top \end{bmatrix} x = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 。根据Farkas引理, 恰有以下之一成立:

(a) 存在 $x \geq 0$ 满足方程

(b) 存在 $\begin{bmatrix} y \\ \lambda \end{bmatrix} \in \mathbb{R}^{m+1}$ 使得:

$$y^\top A + \lambda e^\top \geq 0^\top \quad \text{且} \quad y^\top 0 + \lambda \cdot 1 < 0$$

第二个不等式简化为 $\lambda < 0$ 。

3. 分析对偶条件:

若原系统无解, 则存在 y 和 $\lambda < 0$ 使得:

$$y^\top A_j + \lambda \geq 0 \quad (\forall j = 1, \dots, n)$$

令 $\mu = -\lambda > 0$, 则有:

$$y^\top A_j \geq \mu > 0 \quad (\forall j)$$

即 $A^\top y > 0$, 故系统B成立。

4. 反方向证明:

若系统B有解 (存在 y 使 $A^\top y > 0$), 假设系统A也有解 (存在非零 $x \geq 0$ 使 $Ax = 0$), 则:

$$y^\top Ax = (A^\top y)^\top x > 0 \quad (\text{因 } A^\top y > 0 \text{ 且 } x \geq 0, \neq 0)$$

但左边等于 $y^\top 0 = 0$, 矛盾。故系统B存在时系统A无解。

综上, 系统A与系统B恰有一个成立, Gordon引理得证。 \square

Theorem 1.0.3. Fritz John条件

若 X^* 是局部极小点, 存在不全为零的非负实数 $\mu_j \geq 0, j \in J(X^*) \cup \{0\}$, 使

$$\mu_0 \nabla f(X^*) - \sum_{j \in J} \mu_j \nabla g_j(X^*) = 0$$

Proof. 证明: Gordon引理的直接推论(不存在一个可行的下降方向)

$$\nabla f(X^*)^T P < 0$$

$$-\nabla g_j(X^*)^T P < 0$$

\square

Remark. 等价Fritz John条件(将J显式化)

若 X^* 是局部极小点, 则存在不全为零的非负实数 $\mu_j \geq 0, j = 0, 1, \dots, l$, 使下列条件成立:

$$\begin{cases} \mu_0 \nabla f(X^*) - \sum_{j=1}^l \mu_j \nabla g_j(X^*) = 0 & \text{Lagrange驻点条件} \\ \mu_j g_j(X^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j \geq 0 & \sum_{j=0}^m \mu_j \neq 0 \quad j = 0, 1, \dots, l \quad \text{强非负条件} \end{cases}$$

上述条件隐含了如下事实: $\mu_j = 0 \quad j \notin J$

Definition 1.0.7. Kuhn-Tucker条件

若Fritz John条件的 $\mu_0 \geq 0$ ，则可推出KKT条件的数学形式：

$$\begin{cases} \nabla f(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) = 0 & \text{Lagrange驻点条件} \\ \mu_j^* g_j(X^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j^* \geq 0 & j = 1, 2, \dots, l \quad \text{非负条件} \end{cases}$$

Karush(1939), Kuhn-Tucker (1951)

何老师的问题:什么条件下 $\mu_0 \geq 0$?

在加上约束规格限制时 $\mu_0 \geq 0$ ，比如说正则条件

- **Fritz John点**: 满足Fritz John条件（允许目标函数乘子为零）
- **KKT点**: 满足KKT条件（需约束规格，乘子非负）
- **正则KKT点**: 满足LICQ或严格互补的KKT点
- **极值点**: 局部最优解

— 包含关系:

$$\text{Fritz John点} \supsetneq \text{KKT点} \supsetneq \text{正则KKT点}$$

— 极值点归属:

- * 若满足约束规格: 极值点 \subset KKT点
- * 若不满足约束规格: 极值点 \subset Fritz John点

— 非极值点存在性:

- * 存在非极值的KKT点（如鞍点）
- * 存在非极值的Fritz John点（目标乘子为零）

等价不等式约束极值问题（等式约束改写成不等式）

$$\begin{aligned} & \min f(X) \\ & \text{s.t. } h_i(X) \geq 0 \quad i = 1, 2, \dots, m \\ & \quad -h_i(X) \geq 0 \quad i = 1, 2, \dots, m \end{aligned}$$

$$g_j(X) \geq 0 \quad j = 1, 2, \dots, l$$

$$X \in R^n$$

问题：此时约束是否满足正则条件？

显然不满足，等式约束的梯度函数线性相关

一般约束的KKT条件的推导

$$\mu_0^* \nabla f(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) - \sum_{i=1}^m \mu_i'^* \nabla h_i(X^*) + \sum_{i=1}^m \mu_i''^* \nabla h_i(X^*) = 0$$

$$\mu_0^* \nabla f(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) - \sum_{i=1}^m (\mu_i'^* - \mu_i''^*) \nabla h_i(X^*) = 0$$

$$\mu_0^* \nabla f(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(X^*) = 0$$

$$\mu_i'^* \geq 0 \quad \mu_i''^* \geq 0 \quad \Rightarrow \quad \gamma_i^* = \mu_i'^* - \mu_i''^* \text{ 无符号约束} \quad i = 1, 2, \dots, p$$

注意 μ_0, μ_j, γ_i 不可同时为0!

Definition 1.0.8. 一般约束下的Fritz John条件

若 X^* 是局部极小点，存在不全为零的 μ_j ($j=0,1,2,\dots,m$)和 γ_i ($i=0,1,2,\dots,p$)，满足

$$\mu_0^* \nabla f(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(X^*) = 0 \quad \text{Lagrange驻点条件}$$

$$\mu_j^* g_j(X^*) = 0 \quad j = 1, 2, \dots, m \quad \text{互补松弛条件}$$

$$\mu_j^* \geq 0 \quad j = 0, 1, \dots, m$$

$$\sum_{j=0}^l \mu_j^* + \sum_{i=1}^m |\gamma_i^*| \neq 0 \quad \text{强非负条件}$$

$$\gamma_i^* h_i(X^*) = 0 \quad i = 1, 2, \dots, p \quad \text{等式互补松弛条件}$$

Definition 1.0.9. KKT条件的矩阵形式

$$\nabla f(X^*) - \nabla h(X^*) \gamma^* - \nabla g(X^*) \mu^* = 0$$

$$\mu^* \odot g(X^*) = 0 \quad \Leftrightarrow \quad \mu_j^* g_j(X^*) = 0 \quad j = 1, 2, \dots, l$$

其中

$$g(X^*) \geq 0$$

$$h(X^*) = 0$$

$$\mu^* \geq 0$$

Theorem 1.0.4. 凸规划下的KKT条件为最优解的充要条件

Proof. KKT条件的充分性证明

$$\nabla f(X^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(X^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(X^*) = 0 \quad \mu_j^* g_j(X^*) = 0 \quad \mu_j^* \geq 0$$

$$f(X) \text{ 是凸函数} \Rightarrow f(X) \geq f(X^*) + \nabla f(X^*)^T (X - X^*)$$

$$= f(X^*) + \sum_{i=1}^m \gamma_i^* \nabla h_i(X^*)^T (X - X^*) + \sum_{j=1}^l \mu_j^* \nabla g_j(X^*)^T (X - X^*)$$

$h_i(X)$ 线性函数且 $h_i(X) = 0 \Rightarrow \nabla h_i(X^*)^T (X - X^*) = h_i(X) - h_i(X^*) = 0$ $g_j(X)$ 是凹函数
 $\Rightarrow \nabla g_j(X^*)^T (X - X^*) \geq g_j(X) - g_j(X^*)$ 根据互补松弛性条件 $\mu_j^* g_j(X^*) = 0$ 且 $g_j(X) \geq 0$,
 有

$$f(X) \geq f(X^*) + \sum_{j=1}^l \mu_j^* [g_j(X) - g_j(X^*)] = f(X^*) + \sum_{j=1}^l \mu_j^* g_j(X) \geq f(X^*)$$

□